


Del Prompt al Agente

PROGRAMA DE ESPECIALIZACIÓN EN IA GENERATIVA Y LLMS PARA LA TRANSFORMACIÓN ORGANIZACIONAL · FEN U. DE CHILE · ABRIL 2026

Clase **1 de 3** — Aprenderemos a comunicarnos con los modelos de lenguaje de forma estructurada, entenderemos sus límites reales y daremos los primeros pasos hacia la construcción de agentes inteligentes.



BLOQUE 1

Actividad

60 minutos · Detección de fraude con IA



Estructura de la sesión



Bloque 1 · Actividad

60 min — Detección de fraude con prompts en vivo



Break

10 min — Pausa



Bloque 2 · Cátedra

110 min — Anatomía del prompt → Técnicas → Intro a Agentes

¿Pueden detectar transacciones sospechosas de fraude con IA?



Tienen acceso a:

- **Claude.ai**, Perplexity, similar
- El archivo `generated_data.csv` con transacciones reales

Columnas disponibles:

- `transaction_id` — identificador único
- `amount` — monto en pesos chilenos
- `failed_attempts` — intentos fallidos de autenticación

📋 **Tiempo:** 40 minutos · Escriban el prompt que quieran. No hay respuesta correcta **todavía**.

Fase 1 · Prompt libre

20 MINUTOS

1

Abran la herramienta

Ingresen a Claude.ai o Perplexity desde su navegador

2

Carguen los datos

Adjunten o peguen el contenido del archivo CSV directamente en el chat

3

Escriban su mejor prompt

Usen su mejor criterio para pedirle al modelo que detecte fraude

4

Guarden el resultado

Lo van a necesitar para comparar en la siguiente fase

 No hay pistas. Ese es el punto.



Reflexión grupal · ¿Qué pasó?

Discutan en grupos de 3 las siguientes preguntas:

¿El modelo identificó transacciones sospechosas?

¿Con qué criterio las clasificó?

¿El criterio es auditable?

¿Lo pueden defender ante un jefe o un comité de auditoría?

¿Cambió la respuesta al correrlo dos veces?

Spoiler: probablemente el modelo inventó criterios o fue vago. Eso es normal — y es exactamente lo que vamos a resolver.

Fase 2 · Prompt estructurado

15 MINUTOS

Ahora usen este prompt (se entrega impreso o en pantalla):

CONTEXTO

Eres un experto en auditoría. Sabes que ~1% de las transacciones mensuales son no habituales.

OBJETIVO

Determinar transacciones sospechosas usando técnicas matemáticas auditables.

AUDIENCIA

Audidores y gerentes — no informáticos ni matemáticos.

RESPUESTA

4 documentos: informe para el jefe, gráfico 2D, tabla Excel con criterios y código para automatizar.

Fase 3 · El efecto de la temperatura

15 MINUTOS

Con el **mismo prompt estructurado**, corran 3 veces cambiando la temperatura:

T = 0.0

Determinístico — misma respuesta siempre

T = 0.7

Balance creatividad / coherencia (valor por defecto)

T = 1.0

Creativo — puede variar bastante entre ejecuciones



Pregunta clave: ¿Para auditoría, qué temperatura prefieren? ¿Por qué?

El gran reveal · Lo que descubrieron


Comparación de resultados

Prompt libre	Prompt estructurado
Criterios inventados	Criterios explícitos
Sin metodología	Metodología nombrada
Formato aleatorio	4 documentos específicos
No auditable	Auditable

Pero hay un problema más profundo:


El dataset tiene solo `amount` y `failed_attempts`.
¿Es suficiente para detectar fraude real?

Esta pregunta abre la cátedra.



Break

10 minutos · Volvemos con la cátedra




BLOQUE 2

Cátedra

Anatomía del prompt → Técnicas → Intro a Agentes

¿Por qué falló el primer prompt?



Los LLMs no son adivinos

Un modelo de lenguaje **predice** el texto más probable dado el contexto. No razona por defecto — **simula razonamiento**. Sin instrucciones, elige el camino de menor resistencia.


Lo que pasó en Fase I:

- El modelo completó el patrón "detectar fraude" con lo aprendido en entrenamiento
- Inventó umbrales, criterios y porcentajes sin base en tus datos

📄 El prompt es el contrato entre tú y el modelo.

Anatomía de un prompt · Las 6 capas

Cada capa reduce el espacio de respuestas posibles. Sin capas → el modelo elige por ti.



Capa 1 · Contexto

Dale un rol, no solo una tarea

Sin contexto

"Detecta fraude en estas transacciones"

Con contexto

"Eres un experto en auditoría financiera con experiencia en compliance bancario chileno..."

-  **¿Por qué funciona?** El modelo ajusta su vocabulario, nivel de detalle y estilo al rol asignado. El entrenamiento asocia ese rol a ciertos patrones de respuesta.

Capa 2 · Objetivo

Específico, medible, acotado

 **Vago**

"Analiza las transacciones"

 **Específico**

"Identifica el 1% de transacciones estadísticamente atípicas usando métodos auditables"

El 1% importa — le da al modelo un prior cuantitativo. Sin él, puede reportar 0% o 40% con igual confianza aparente.

Capa 3 · Restricciones

Lo que NO debe hacer es tan importante como lo que SÍ debe

→ "No inventes columnas o variables que no están en el dataset"

→ "No uses jerga técnica incomprensible para auditores"

→ "Si no tienes suficiente información para concluir, dilo explícitamente"

→ "No hagas supuestos sobre el negocio sin mencionarlos"



Las restricciones protegen contra las **alucinaciones más comunes** en contextos de negocio.

Capa 4 · Formato de salida

El modelo entrega lo que le pides

JSON

Para integrar con sistemas

Markdown

Para reportes

CSV

Para tablas

Python / SQL

Para automatizar

La clase de hoy usó:

- 1 Informe para el jefe
- 2 Gráfico 2D
- 3 Tabla Excel con criterios
- 4 Código para automatizar

→ 4 artefactos distintos en un solo prompt.

Temperatura · La variable más mal entendida

La temperatura modifica la distribución de probabilidad sobre el siguiente token:

T = 0.0 · Determinístico

Siempre el token más probable.
Reproducible al 100%.

Ideal para: análisis, código,
auditoría



T = 0.7 · Balanceado

Algo de variación controlada.
Es el valor por defecto de la
mayoría de los modelos.

Ideal para: resúmenes,
clasificación



T = 1 · Creativo (máximo 2)

Alta variación. Puede ser
impredecible entre ejecuciones.

Ideal para: brainstorming,
escritura creativa



Regla práctica: si el resultado tiene que ser el mismo la próxima vez → T=0.

El límite del prompt


Lo que ningún prompt puede arreglar

Nuestro dataset actual:


transaction_id	amount	failed_attempts
1	604.252	0
53	16.951	2

¿Qué falta para detectar fraude real?

- Historial del cliente
- Hora de la transacción
- Canal (web, app, sucursal)
- Ubicación geográfica
- Categoría del comercio
- Etiqueta de fraude conocido (is_fraud = 1/0)



❏ El prompt no compensa datos pobres. Esto es crítico en analytics aplicado.



Basura entra, basura sale · Edición 2026

Con ML clásico (2015)

Datos malos → modelo malo → decisión mala

El modelo simplemente da un número incorrecto.

Con LLMs (2026)

Datos malos + prompt malo → **respuesta confiada y equivocada**

El LLM **suen**a bien aunque esté inventando.

El riesgo de los LLMs no es que fallen — es que fallen con elocuencia.

Chain of Thought (CoT, Cadena. de Razonamiento)

Pedirle al modelo que piense en voz alta

✗ Sin CoT

"¿Es esta transacción fraudulenta? Sí/No"

✓ Con CoT

"Antes de responder, analiza paso a paso: (1) ¿El monto es atípico para este cliente? (2) ¿Hay intentos fallidos recientes? (3) ¿Coincide con patrones históricos de fraude? Luego concluye."

📌 **¿Por qué funciona?** Fuerza al modelo a generar tokens intermedios de razonamiento, aumentando la probabilidad de llegar a la respuesta correcta.

Few-shot prompting

Enseñar con ejemplos dentro del prompt

Los ejemplos anclan el criterio de clasificación — el modelo no lo inventa.

Ejemplo 1 → SOSPECHOSA

amount=450.000,
failed_attempts=3 Criterio:
intentos fallidos elevados

Ejemplo 2 → NORMAL


amount=12.000,
failed_attempts=0 Criterio: monto
bajo, sin intentos fallidos

Ejemplo 3 → REVISAR

amount=890.000,
failed_attempts=0 Criterio: monto
muy alto, puede ser legítima

Prompt de Sistema vs. Prompt de Usuario

Dos niveles de instrucción



¿Cuándo usar cada uno?

Prompt de Sistema

Restricciones de negocio, tono corporativo y formatos obligatorios. Configura el modelo una vez.

Prompt de Usuario

La tarea específica de cada conversación. Cambia constantemente.


📄 En Claude.ai: configurar en **Projects** → **System Prompt**

Prompting vs. Fine-tuning

¿Cuándo no alcanza el prompt?

Situación	Solución recomendada
Tarea general, bien descrita	Prompting
Necesito un estilo muy específico	Few-shot prompting
Tengo miles de ejemplos etiquetados	Fine-tuning
El conocimiento no está en el modelo	RAG (próxima clase)
El modelo base es insuficiente	Fine-tuning + RAG

 **Regla:** siempre partir por prompting. Es lo más barato, lo más rápido y lo más mantenible.



Del Prompt al Agente

El prompt es el núcleo — el agente es la envoltura.



Herramientas

Ejecutar código, buscar en web, leer archivos



Memoria

Recuerda contexto entre conversaciones




Bucle

Puede revisar su propia respuesta y corregirla

La diferencia entre un prompt y un agente es que el agente **actúa**, no solo responde.

Arquitectura mínima de un agente



¿Cómo decide el agente?

El LLM actúa como el cerebro central: recibe las instrucciones del system prompt, razona sobre la tarea y decide **cuándo y cómo** invocar cada herramienta.

buscar_web

Información actualizada

ejecutar_sql

Consultar bases de datos

leer_archivo

Procesar documentos

Ejemplo · Agente de auditoría

Lo que construirán en Clase 2

Tarea: dado un reporte financiero mensual, detectar anomalías automáticamente — sin intervención humana paso a paso.



leer_csv(archivo)

Carga el dataset de transacciones



calcular_estadisticas(columna)

Media, desviación estándar, percentiles



graficar(datos)

Genera visualizaciones automáticas



generar_informe(hallazgos)

Redacta el reporte corporativo final

El estado del arte · Abril 2026

Modelos líderes hoy:

Claude Opus 4 / Sonnet 4

Anthropic

GPT-4o, o3

OpenAI

Gemini 2.5 Pro

Google

Llama 4

Meta · Open source

Tendencias confirmadas:

→ Contextos de 1M+ tokens


Documentos completos en un solo prompt

→ Razonamiento extendido

o3 y Claude 3.7+ mejoran en matemáticas y lógica

→ Agentes en producción

Ya no son solo demos — están en sistemas reales



Lo que los LLMs hacen bien en negocios



Resumir documentos

Síntesis de textos largos con precisión



Clasificar texto

Categorización a escala con instrucciones claras



Redactar con formato

Informes, correos, contratos con estructura definida



Extraer información estructurada

Parsear documentos no estructurados



Análisis de datos con código

Generar y ejecutar código de análisis



Razonamiento causal complejo

Requiere CoT y verificación adicional

Lo que los LLMs NO hacen bien

Confiar en ellos para esto es riesgoso



Aritmética precisa

Cometen errores sin herramientas externas de cálculo



Fechas y tiempos

Confunden contexto con fecha de entrenamiento



Información actualizada

Tienen fecha de corte — no conocen eventos recientes



Consistencia con T alta

Resultados variables en tareas que requieren exactitud



Auditoría sin estructura

Sin prompt estructurado y datos suficientes, los criterios son arbitrarios

📌 El ejercicio de hoy lo demostró en vivo.

Alucinación · El riesgo más subestimado

El modelo siempre da una respuesta – aunque no sepa

¿Por qué ocurre?

El modelo fue entrenado para **completar texto**. "No sé" es una respuesta poco probable en su corpus de entrenamiento — por eso siempre genera algo plausible.

Señales de alerta:

- Cifras muy precisas sin fuente citada
- Nombres de leyes, normativas o personas específicas
- Conclusiones muy rotundas con datos pobres

Mitigación:

Pedir fuentes explícitas

"Cita la fuente de cada afirmación"

Pedir incertidumbre

"Indica si no tienes suficiente información"

Verificar con herramientas

RAG — lo veremos en la próxima clase




"Ingeniería de prompts" en el trabajo real

No es una habilidad técnica — es una habilidad de comunicación.

- 1 Describe el contexto como lo haría con un consultor externo muy capaz
 - 2 Define el entregable con precisión de contrato
 - 3 Anticipa los errores más probables y los prohíbe explícitamente
 - 4 Pide transparencia metodológica en el razonamiento
- ❑ **Quién lo hace mejor:** quien mejor entiende el problema de negocio, no quien sabe más de tecnología.

Iteración · El prompt nunca es final

Proceso real de prompt engineering



En producción, los prompts se tratan como código: con **control de versiones**, tests automatizados y revisión periódica. Un prompt que funcionaba bien puede degradarse si cambian los datos de entrada o el modelo subyacente.

Evaluación de prompts

¿Cómo sé si mi prompt es bueno?

Criterio	Pregunta de evaluación
Reproducibilidad	¿Obtengo el mismo resultado dos veces con T=0?
Cobertura	¿Identifica todos los casos que debería?
Precisión	¿Lo que identifica realmente es sospechoso?
Auditabilidad	¿Puedo explicar el criterio a mi jefe?
Formato	¿El output se puede usar directamente?

❏ Sin estas métricas, el prompt es intuición — no ingeniería.

Síntesis de la clase

01

Un prompt sin estructura produce resultados arbitrarios

03

Los datos importan tanto como el prompt – basura entra, basura sale

05

El prompt es un contrato: contexto + objetivo + restricciones + formato

02

La temperatura controla la variabilidad – usar $T=0$ en tareas críticas

04

El LLM no detecta lo que no está en los datos

06

Los agentes son la extensión natural del prompting – actúan, no solo responden

Tarea para la próxima clase



El desafío:

Tomen un problema real de su trabajo o área de estudio y escriban un prompt estructurado usando las **6 capas** vistas hoy.

Traigan:

- El problema elegido
- El prompt completo con sus 6 capas
- El resultado obtenido
- Una reflexión: ¿qué faltó en los datos o en el prompt?

📌 **Próxima clase:** construiremos un agente que use herramientas — su prompt estructurado puede ser la base.

Recursos recomendados

Para profundizar – todo disponible en 2026



Anthropic Prompt Library

Prompts organizados por industria y caso de uso, con ejemplos listos para adaptar




OpenAI Cookbook

Ejemplos técnicos con código reproducible para aplicaciones reales



OWASP LLM Top 10

Riesgos de seguridad en aplicaciones con LLMs — lectura obligada para producción



DeepLearning.ai

"Building LLM Applications" — curso gratuito con casos prácticos de negocio

PROGRAMA DE ESPECIALIZACIÓN EN IA GENERATIVA Y LLMS PARA LA
TRANSFORMACIÓN ORGANIZACIONAL · FEN U. DE CHILE · ABRIL 2026

Clase 1 de 3

Del Prompt al Agente — Nos vemos en la Clase 2.

