

Attention Is All You Need

Vaswani et al. (2017) — El paper que cambió el NLP

Sebastián Egaña Santibáñez

Módulo 3 · IA Generativa y LLMs
FEN Unegocios, Universidad de Chile

Abril 2026

Agenda

- 1 El problema que existía
- 2 La propuesta: solo atención
- 3 El mecanismo de atención
- 4 La arquitectura Transformer
- 5 Por qué fue tan influyente
- 6 Implicancias prácticas
- 7 Síntesis

Antes de 2017: modelos que leían de izquierda a derecha

Modelo predominante: RNN / LSTM

- Procesan texto **token a token**, en secuencia
- Para entender la palabra 10, deben “recordar” las 9 anteriores
- La información tiene que **sobrevivir** muchos pasos intermedios

El límite práctico

En frases largas, el modelo *olvidaba* detalles del principio antes de llegar al final.



Cada flecha pasa información al siguiente paso

El cuello de botella: dependencias largas

Ejemplo del curso

*“El analista revisó el informe porque necesitaba verificar si los **beneficios** estaban correctamente **calculados**.”*

Problema con RNN:

- Para conectar *beneficios* con *calculados*, la información debe pasar por todos los tokens intermedios
- Cuantos más tokens intermedios → más probabilidad de “diluirse”
- No puede paralelizarse → entrenamiento lento

¿Qué queríamos?

- Que cualquier palabra pudiera “hablarle directamente” a cualquier otra
- Sin importar la distancia
- **Y en paralelo**, para escalar

Esa es exactamente la propuesta del paper.


“Attention is all you need” — la apuesta central

La tesis del paper (Vaswani et al., 2017)

Es posible construir un modelo de lenguaje de alta calidad **sin recurrencia ni convoluciones**, usando únicamente mecanismos de atención.

Lo que propone el Transformer:

- 1 Cada token mira a *todos* los demás tokens a la vez
- 2 Les asigna un peso según cuán relevantes son
- 3 Construye su representación a partir de ese peso
- 4 **Todo en paralelo** — no en secuencia



Cada token
se conecta con todos

La intuición: ¿qué es “prestar atención”?

Definición operativa

La atención es el mecanismo que permite al modelo **ponderar qué partes del contexto son más relevantes** en cada momento.

Cuando el modelo genera o representa una palabra:

- Mira *todos* los tokens del contexto
- Estima cuáles son más relevantes
- Les da **más peso** a algunos
- Y **menos peso** a otros

No recuerda todo igual: prioriza dinámicamente.

Ejemplo: “banco”

*“Fui al **banco** a depositar el cheque.”*

Tokens de alto peso: depositar, cheque

Tokens de bajo peso: Fui, al, a

⇒ El modelo infiere “banco” = institución financiera

Queries, Keys y Values — sin fórmulas

Cada token genera **tres vectores**:

- Query (Q)** *¿Qué estoy buscando?*
La pregunta que hace el token actual
- Key (K)** *¿Qué tipo de información tengo?*
Lo que cada token “ofrece”
- Value (V)** *¿Cuál es mi contenido?*
La información que entregará si es relevante

El modelo compara Q con cada K → obtiene un puntaje → pondera los V.

Analogía: pregunta sobre pensiones

Pregunta (Query):

“¿Qué documentos necesito para pensionarme?”

Fragmentos relevantes (Keys con alto match):

certificados, edad legal, formulario, solicitud

Contenido que se ponderará más (Values):

requisitos, plazos, documentación


Scaled Dot-Product Attention — la mecánica

En palabras simples:

- 1 Para el token actual, toma su **Query**
- 2 Compárala contra las **Keys** de todos los demás tokens (producto punto)
- 3 Normaliza los puntajes (softmax $\Rightarrow$ suman 1)
- 4 Multiplica cada puntaje por el **Value** correspondiente
- 5 Suma ponderada = nueva representación del token

Por qué “scaled”

El producto punto crece con la dimensión del vector. Se divide por $\sqrt{d_k}$ para estabilizar el gradiente durante el entrenamiento.




Multi-Head Attention — mirar con varios lentes

¿Por qué múltiples cabezas?

- Una sola atención captura *un tipo* de relación a la vez
- Con múltiples cabezas en paralelo, el modelo puede capturar **distintos tipos de dependencias simultáneamente**:
 - sintácticas (sujeto-verbo)
 - semánticas (causa-efecto)
 - correferenciales (pronombre-referente)

Los resultados de cada cabeza se concatenan y se proyectan en una representación final.



Arquitectura Encoder-Decoder

Encoder (comprende la entrada):

- 1 Input Embeddings + Positional Encoding
- 2 Bloque $\times N$:
 - **Multi-Head Self-Attention**
 - Add & Norm
 - Feed-Forward Network
 - Add & Norm

Decoder (genera la salida):

- 1 Output Embeddings + Positional Encoding
- 2 Bloque $\times N$:
 - **Masked** Multi-Head Self-Attention
 - Add & Norm
 - **Cross-Attention** (mira al encoder)
 - Add & Norm
 - Feed-Forward Network
 - Add & Norm
- 3 Linear + Softmax $\rightarrow$ token de salida

Positional Encoding

Como la atención no es secuencial, hay que *inyectar* la posición de cada token. Se suman señales sinusoidales a los embeddings.


¿Por qué Masked Self-Attention en el Decoder?

Problema: al *generar* texto, el modelo no puede ver palabras que aún no ha producido.

Solución: durante el entrenamiento se aplica una **máscara** que bloquea el acceso a posiciones futuras.

Intuición

Si el modelo ya generó “*El informe fue*”, al predecir la siguiente palabra solo puede mirar esos tres tokens — no los que vendrán después.



Solo mira hacia atrás

El impacto: RNN vs. Transformer

Criterio	RNN / LSTM	Transformer
Procesamiento	Secuencial	Paralelo
Dependencias largas	Se diluyen	Acceso directo
Escalabilidad	Limitada	Alta
Velocidad de entrenamiento	Lenta	Mucho más rápida
Captura de contexto	Local	Global

Por qué la paralelización importa tanto

Los modelos modernos tienen miles de millones de parámetros. Sin paralelización no sería posible entrenarlos en tiempo razonable. El Transformer es lo que hace viable el escalado a GPT-4, Claude, Gemini, etc.

Resultados del paper — BLEU en traducción

Tarea: traducción EN→DE e EN→FR (WMT 2014)

Modelo	BLEU EN→DE
Mejor RNN ensemble	26.4
ConvS2S	26.4
Transformer (base)	27.3
Transformer (big)	28.4

BLEU = métrica estándar de calidad de traducción (0–100)


El dato clave

Superó al estado del arte con **menos costo computacional** de entrenamiento que los modelos previos.

No solo mejor calidad: también más eficiente.

El paper también probó análisis de constituyentes del inglés, mostrando que la arquitectura generaliza más allá de la traducción.

De 2017 a hoy: la línea directa



Todos son Transformers. La arquitectura de 2017 sigue vigente.

Atención y calidad del prompt

La atención no es una caja negra irrelevante para nosotros.

- La forma en que escribimos un prompt **afecta qué partes del contexto destacan más**
- Si el contexto está mal armado, el modelo puede enfocarse en lo menos importante
- Un buen prompt también *guía* la atención del modelo

Por eso ayuda...

- Separar instrucciones de contexto
- Usar formato claro (listas, secciones)
- Destacar restricciones críticas
- Ordenar bien la información
- No enterrar restricciones importantes en texto largo

Caso aplicado: instrucción crítica en el agente AFP

Escenario

Una AFP implementa un agente que responde preguntas de afiliados. El contexto tiene 5.000 tokens de normativa mezclada.

Prompt mal estructurado:

*[... 3.000 tokens de normativa. ...]
Importante: si no tienes certeza, di "no sé".
[... 2.000 tokens más. ...]*

Riesgo: la instrucción crítica queda diluida. El modelo puede ignorarla.

Prompt bien estructurado:

Sistema: *"Si no tienes certeza, responde: 'No tengo información suficiente'. Usa solo la normativa adjunta."
[normativa bien segmentada]*

Resultado: la instrucción recibe alta atención; el modelo la respeta.

Lo que la atención NO garantiza

A pesar de su potencia, la atención **no resuelve todo**:

- **No garantiza verdad factual** — puede ponderar bien tokens incorrectos
- **No garantiza razonamiento correcto** — pesar bien $\neq$ razonar bien
- **No garantiza priorización adecuada** — depende de cómo está construido el contexto
- **No elimina las alucinaciones**

Regla simple

Si el contexto está mal armado, el modelo puede enfocarse en lo menos importante.

La calidad del input determina la calidad de la atención.

Por eso la gobernanza y el diseño cuidadoso del prompt son parte de cualquier solución seria.

Síntesis: ¿qué cambió Attention Is All You Need?

Dimensión	Aporte
Arquitectura	Reemplazó RNN/LSTM por atención pura
Paralelización	Permitió entrenar en paralelo → escalar a miles de millones de parámetros
Contexto global	Cualquier token puede relacionarse con cualquier otro directamente
Fundamento	Es la base de GPT, BERT, Claude, Gemini, Llama y prácticamente todos los LLMs vigentes
Práctica	La calidad del prompt influye en qué partes del contexto reciben más atención

“Gran parte del salto de los LLMs modernos pasa por este mecanismo.”

Actividad de reflexión

Para discutir en grupos (15–20 min)

Con base en el abstract e introducción del paper (Vaswani et al., 2017):

- ❶ ¿Qué limitación de los modelos anteriores identifica el paper?
- ❷ ¿Cuál es la propuesta central del Transformer?
- ❸ ¿Por qué la atención aparece como una innovación tan importante?
- ❹ ¿Qué conexión ven entre este paper y los LLMs que usamos hoy?

Producto esperado — mini-síntesis de 3 partes:

Problema anterior ¿qué estaba fallando o limitando a los modelos previos?

Aporte del paper ¿qué cambia con el Transformer?

Impacto actual ¿por qué esto sigue importando hoy?

Gracias

Sebastián Egaña Santibáñez

Módulo 3 · IA Generativa y LLMs
FEN Unegocios, Universidad de Chile

Vaswani, A. et al. (2017). *Attention Is All You Need*. NeurIPS.
<https://arxiv.org/abs/1706.03762>