

IA Generativa y LLMs para la Transformación Organizacional

Funcionamiento práctico, implementación y riesgos

2026-04-20

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Clase 02

De la comprensión técnica a la implementación organizacional

Cómo funcionan los LLMs, cómo se controlan y cómo se adoptan con criterio

Objetivo de la sesión

- Entender cómo procesan texto los LLMs
 - Revisar conceptos operativos como tokens, embeddings y contexto
 - Distinguir parámetros de entrenamiento y de generación
 - Evaluar implicancias estratégicas para transformación organizacional
 - Identificar riesgos éticos, legales y de gobernanza
-

Pregunta de continuidad

Si ya entendemos qué lugar ocupa un LLM en el stack, la siguiente pregunta es esta:

¿Qué debemos comprender para usarlo bien, controlarlo mejor y desplegarlo con responsabilidad?

Cómo procesan texto los LLMs

Idea central

Un LLM no trabaja con “palabras” como las vemos nosotros.

Opera sobre representaciones numéricas y calcula probabilidades de continuación en función del contexto disponible.

Tokens

Los LLMs dividen el texto en **tokens**, que pueden ser:

- fragmentos de palabra
- palabras completas
- signos de puntuación
- números o símbolos frecuentes

Implicancia práctica

- más tokens implican más costo
 - todo input y output se mide en tokens
 - el límite real de trabajo del modelo depende de su ventana de contexto
-

Ejemplo simple de tokenización

La frase:

“La inteligencia artificial generativa cambia procesos.”

podría dividirse en piezas como:

- La
- intelig
- encia
- artificial
- generativa
- cambia
- procesos
- .

Idea clave

El modelo no “lee” el texto literal: transforma esas piezas en unidades procesables.

Embeddings

Cada token se convierte en un **vector numérico** en un espacio de muchas dimensiones.

Ese vector representa relaciones como:

- significado
- cercanía semántica
- contexto de uso
- similitud con otros conceptos

Idea clave

Los embeddings son el “idioma interno” del modelo.

Qué aprende el modelo

Durante el entrenamiento, el modelo observa enormes cantidades de texto y aprende regularidades estadísticas:

- qué secuencias suelen aparecer juntas
- qué palabras cumplen roles parecidos
- qué patrones son plausibles en distintos contextos

Resultado

Palabras o conceptos usados en contextos similares tienden a quedar cerca en el espacio vectorial.

Ejemplo conceptual de embeddings

Palabra	Eje X	Eje Y
gato	0.90	0.95
perro	0.85	0.97
lobo	0.88	0.30
avión	0.10	0.05

Lectura

- gato y perro quedan cerca
 - lobo comparte una dimensión, pero se distancia en otra
 - avión queda fuera del grupo
-

Ventana de contexto

La **context window** es la cantidad máxima de tokens que el modelo puede considerar al mismo tiempo.

Importa porque afecta:

- cuánto puede “recordar” en una interacción
- cuántos documentos o instrucciones caben en una consulta
- el costo total del procesamiento
- la calidad cuando la tarea exige mantener coherencia en textos largos

Idea útil

Más contexto no reemplaza la necesidad de buena selección de información.

De texto a predicción

El ciclo básico del modelo puede simplificarse así:

1. Recibe tokens de entrada.
2. Los representa como embeddings.
3. Calcula relaciones entre ellos dentro del contexto.
4. Estima probabilidades para el siguiente token.
5. Repite el proceso hasta completar la respuesta.

Frase clave

Los LLMs no “piensan” como humanos: optimizan predicción secuencial sobre lenguaje.

Parámetros que importan

Dos familias distintas

1. Parámetros de entrenamiento

Definen la capacidad y el comportamiento potencial del modelo.

2. Parámetros de generación

Controlan cómo responde el modelo en inferencia.

Parámetros de entrenamiento

- **Tamaño del modelo:** cantidad de parámetros internos
- **Embedding dimension:** riqueza de representación semántica
- **Número de capas y atención:** profundidad del procesamiento
- **Batch size:** estabilidad y eficiencia durante entrenamiento
- **Longitud del pre-training:** cantidad y calidad de aprendizaje acumulado
- **Context window:** tamaño máximo del contexto procesable

Idea clave

Más grande no siempre significa mejor: importa también la calidad de datos, arquitectura y fine-tuning.

Parámetros de generación

- **Temperature:** nivel de aleatoriedad
- **Top-p:** diversidad probabilística permitida
- **Top-k:** cantidad de candidatos posibles
- **Repetition penalty:** control de repeticiones
- **Max tokens:** largo máximo de la salida

Implicancia práctica

Estos parámetros no cambian lo que el modelo sabe, sino cómo expresa su respuesta.

Temperatura

- baja: respuestas más estables, conservadoras y repetibles
- alta: respuestas más variadas, creativas y riesgosas

Regla simple

- análisis, clasificación o extracción: temperatura baja
 - ideación, redacción creativa o exploración: temperatura más alta
-

Top-p y Top-k

Son dos formas de restringir el conjunto de opciones que el modelo puede elegir al generar.

Uso práctico

- valores más restrictivos favorecen precisión y consistencia
- valores más amplios favorecen diversidad estilística

Criterio

No conviene ajustar demasiados controles a la vez sin un objetivo claro de calidad.

Max tokens

Define cuánto puede extenderse la respuesta.

Si el valor es muy bajo:

- la salida puede truncarse
- puede perder pasos importantes

Si el valor es muy alto:

- sube el costo
 - aumenta el riesgo de verbosidad o deriva
-

Resumen operativo

Concepto	Rol práctico
Token	Unidad mínima procesada
Embedding	Representación numérica del significado
Context window	Memoria de corto plazo del modelo
Temperature	Aleatoriedad
Top-p / Top-k	Diversidad controlada
Max tokens	Extensión de salida

Un ejemplo mínimo con embeddings

Flujo conceptual

1. Convertir textos en vectores
2. Guardarlos en un índice vectorial
3. Transformar una nueva consulta en vector
4. Buscar los vectores más cercanos
5. Recuperar texto relevante para responder mejor

Esto está en la base de muchos sistemas RAG

Ejemplo en Python

```
from openai import OpenAI
import numpy as np
import faiss

client = OpenAI()

sentences = [
    "The dog is barking.",
    "A cat is sleeping on the couch.",
    "A car is driving down the street.",
    "I love my pet animal."
]

response = client.embeddings.create(
    model="text-embedding-3-small",
    input=sentences
)
```

```
vectors = np.array([item.embedding for item in response.data])

index = faiss.IndexFlatL2(vectors.shape[1])
index.add(vectors)

query = "My puppy is barking loudly."
query_vec = client.embeddings.create(
    model="text-embedding-3-small",
    input=query
).data[0].embedding

D, I = index.search(np.array([query_vec]), k=2)
print(I)
```

Qué muestra este ejemplo

- el modelo representa cada texto como vector
- la similitud semántica puede buscarse matemáticamente
- eso permite recuperar contexto útil antes de pedir una respuesta al LLM

Traducción organizacional

No solo importa el modelo: importa cómo se conecta con información relevante.

Entrenamiento y prompting

Entrenamiento

El modelo aprende patrones desde grandes volúmenes de datos.

Prompting

El usuario orienta la tarea mediante instrucciones, contexto y formato esperado.

Idea clave

Un prompt no reemplaza el entrenamiento del modelo, pero sí condiciona fuertemente su desempeño en una tarea concreta.

Discriminativos vs generativos

- **Discriminativos:** clasifican, estiman o predicen
- **Generativos:** producen contenido nuevo

Analogía

- discriminativo: “¿es fraude o no?”
- generativo: “resume este caso de fraude y explica sus patrones”

En organizaciones

Ambos enfoques pueden convivir dentro del mismo proceso.

Implicancias estratégicas

¿Reemplazo o colaboración?

La evidencia práctica muestra algo más matizado que el reemplazo total.

Idea clave

La IA reemplaza tareas, reorganiza procesos y redefine roles; rara vez reemplaza una profesión completa de forma inmediata.

Transformación organizacional

La IA generativa impacta:

- procesos
- tiempos de decisión
- productividad individual
- coordinación entre equipos
- creación de nuevos productos y servicios

La pregunta estratégica ya no es solo “usar IA”

Es rediseñar el trabajo para capturar valor real.

Alineamiento estratégico

La IA genera valor cuando se conecta con objetivos de negocio medibles.

Principios

- vincular iniciativas con KPIs reales
 - priorizar casos de alto impacto y riesgo manejable
 - evitar pilotos aislados sin continuidad
 - construir una hoja de ruta de adopción
-

Cambio cultural y alfabetización

El mayor freno a la adopción suele ser organizacional, no técnico.

Cambios necesarios

- pasar de trabajo manual a trabajo aumentado por IA
 - desarrollar criterio para evaluar respuestas
 - normalizar la experimentación controlada
 - entrenar a equipos en uso y límites de los modelos
-

Gobernanza y gestión del riesgo

Una organización debería evaluar al menos estas dimensiones:

- seguridad y privacidad de datos
 - sesgos y fairness
 - trazabilidad de decisiones
 - cumplimiento regulatorio
 - políticas de uso responsable
 - supervisión humana en procesos críticos
-

Identificación de oportunidades

Tres arquetipos útiles para clasificar casos de uso:

Augmentation

La IA ejecuta parte de la tarea y el humano mantiene control.

Co-creation

Humano e IA producen conjuntamente el resultado.

Replacement

La IA automatiza la tarea o proceso bajo condiciones controladas.

Criterios para detectar oportunidades

- la tarea es repetitiva
- consume mucho tiempo
- exige redactar, resumir o clasificar
- el output puede verificarse
- existe impacto claro en costo, calidad o velocidad

Criterio adicional

Mientras más alto el riesgo del proceso, mayor debe ser el nivel de control y trazabilidad.

Framework operativo

1. Mapear procesos

Identificar microtarefas y puntos de dolor concretos.

2. Experimentar

Probar, medir y ajustar prompts, contexto y flujos.

3. Escalar

Integrar en sistemas, entrenar equipos y monitorear resultados.

Redistribución de capacidades

La IA cambia qué hacen las personas y cómo se organiza el trabajo.

Efectos esperables

- menos tiempo en tareas repetitivas
- más foco en supervisión, análisis y decisión
- mayor autonomía en roles operativos
- aparición de nuevos roles ligados a IA

Ejemplos

- AI Product Owner
 - Model Steward
 - AI Trainer
 - Especialistas de procesos aumentados
-

Ética, privacidad y riesgos

Sesgos

Los modelos pueden amplificar desigualdades presentes en los datos.

Fuentes frecuentes

- datos desbalanceados
 - variables sensibles directas o indirectas
 - falta de representatividad
 - ausencia de validación ética en diseño y despliegue
-

Cómo detectar y mitigar sesgos

Detección

- evaluar desempeño en subgrupos
- auditar resultados
- monitorear continuamente

Mitigación

- rebalancear datos
 - rediseñar variables
 - incorporar supervisión humana
 - medir fairness desde el inicio
-

Privacidad

La personalización puede aumentar valor, pero también eleva exposición de datos.

Riesgos

- uso indebido de datos sensibles
- envío de información a terceros
- retención excesiva
- entrenamiento no autorizado sobre datos internos

Mitigaciones

- minimización de datos
 - anonimización y cifrado
 - políticas claras de consentimiento
 - modelos privados cuando el caso lo exija
-

Copyright y propiedad intelectual

Los problemas más comunes son:

- autoría del contenido generado
- uso de material protegido en entrenamiento
- derechos de imagen
- infracción involuntaria por parte del usuario

Respuesta organizacional

Documentar fuentes, licencias, proveedores y condiciones de uso.

Explicabilidad y cajas negras

Muchos sistemas de IA son difíciles de interpretar internamente.

Riesgos

- baja confianza
- dificultad de auditoría
- problemas regulatorios
- escasa trazabilidad en decisiones sensibles

Respuesta práctica

Usar documentación, monitoreo, validación y modelos más interpretables cuando corresponda.

Accountability

La responsabilidad por decisiones apoyadas por IA no desaparece.

Problemas típicos

- nadie asume errores del sistema
- se usa “lo dijo la IA” como justificación
- se automatizan decisiones críticas sin revisión humana

Regla

Siempre debe existir un responsable humano claro.

Riesgos emergentes

- deepfakes y manipulación
- desinformación a escala
- automatización fuera de límites esperados
- riesgos reputacionales y de ciberseguridad

Idea clave

La velocidad de adopción no elimina la necesidad de controles.

Ética por diseño

Los principios éticos deben estar integrados desde el inicio del proyecto.

Principios mínimos

- objetivos explícitos
 - gestión responsable de datos
 - transparencia
 - evaluación de sesgos
 - monitoreo continuo
 - revisión de impacto social
-

Cierre

Comprender LLMs no significa solo saber “qué son”.

Significa entender:

- cómo representan lenguaje
- cómo se controlan en operación
- cómo se integran en procesos
- cómo se gobiernan en contextos reales

La ventaja no está en usar IA antes que otros

Está en usarla con mejor diseño técnico, mejor criterio organizacional y mejor gestión del riesgo.

Referencias sugeridas

- Vaswani et al. (2017). *Attention Is All You Need*. <https://arxiv.org/abs/1706.03762>
- OpenAI. Guías sobre embeddings y uso por API.
- Hugging Face. Documentación introductoria sobre embeddings y modelos open source.
- Materiales de gobernanza y adopción responsable de IA aplicados a negocio.