

Conceptos Básicos de IA y LLM en la Actualidad

Lenguaje común para entender el panorama actual

2026-04-30

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Clase 03

Conceptos básicos de IA y LLM hoy

Un mapa simple para entender el lenguaje actual de la inteligencia artificial

Objetivo de la sesión

- Entender los conceptos más usados hoy en conversaciones sobre IA
 - Diferenciar IA, IA generativa, LLM, agentes y automatización
 - Reconocer qué significan términos como prompts, RAG, embeddings y MCP
 - Traducir ese vocabulario a decisiones prácticas de negocio
 - Identificar oportunidades, límites y riesgos reales
-

Pregunta de apertura

Cuando escuchan hablar de IA hoy, ¿qué es lo primero que aparece?

- ChatGPT o asistentes conversacionales
 - Automatización de tareas
 - Análisis de documentos
 - Generación de contenido
 - Riesgos y reemplazo laboral
-

El mapa general

IA no es una sola cosa

Cuando hoy se habla de IA, normalmente se mezclan varias capas:

- inteligencia artificial
- machine learning
- IA generativa
- LLMs
- herramientas, datos y automatización

Idea clave

Un chatbot visible para el usuario suele ser solo la punta del sistema.

IA

Inteligencia Artificial es un concepto amplio.

Se usa para describir sistemas capaces de realizar tareas asociadas a inteligencia humana, por ejemplo:

- clasificar
 - predecir
 - recomendar
 - reconocer patrones
 - generar contenido
-

Machine Learning

Machine Learning es una forma de construir IA usando datos para aprender patrones.

Ejemplos comunes

- detectar fraude
- predecir rotación de clientes
- recomendar productos
- estimar demanda

Idea simple

No todas las soluciones de IA conversan; muchas solo predicen o clasifican.

IA generativa

La **IA generativa** crea contenido nuevo a partir de patrones aprendidos.

Puede generar

- texto
- imágenes
- audio
- video
- código

Lo importante

Su valor no está solo en “crear”, sino en acelerar trabajo cognitivo.

LLM

LLM significa **Large Language Model**.

Son modelos entrenados con grandes volúmenes de texto para trabajar con lenguaje.

Hacen bien tareas como

- responder preguntas
 - resumir
 - redactar
 - traducir
 - clasificar texto
 - extraer información desde documentos
-

Copilot, chatbot y asistente

No son exactamente lo mismo:

- **chatbot**: responde en formato conversacional
- **asistente**: ayuda a una persona en una tarea
- **copilot**: acompaña el trabajo dentro de una herramienta o flujo

Ejemplo

Un copiloto en Word o Excel no reemplaza el software: lo vuelve más asistido.

Multimodalidad

Un sistema **multimodal** puede trabajar con más de un tipo de información.

Hoy puede combinar

- texto
- imágenes
- audio
- video
- documentos

Implicancia práctica

La IA actual ya no solo “lee”: también puede ver, escuchar e interpretar.

Token

Los modelos no procesan texto exactamente como nosotros lo vemos.

Trabajan con **tokens**, pequeñas unidades de texto.

Por qué importa

- el costo suele medirse en tokens
 - el largo de una conversación depende de tokens
 - los documentos grandes consumen tokens rápidamente
-

Ventana de contexto

La **context window** es la cantidad de información que el modelo puede considerar al mismo tiempo.

Traducción simple

Es como su memoria de corto plazo dentro de una conversación o tarea.

Importa porque afecta

- cuánta información cabe
 - cuán largo puede ser un documento
 - cuánta coherencia puede mantener
-

Prompt

Un **prompt** es la instrucción que damos al modelo.

Puede incluir

- la tarea
- contexto
- restricciones
- formato esperado
- ejemplos

Idea clave

Un buen prompt no es “hablar bonito con la IA”; es diseñar bien la instrucción.

Prompt engineering

Es la práctica de mejorar resultados ajustando instrucciones y contexto.

Normalmente busca

- mayor claridad
- menos ambigüedad
- mejor formato de salida
- menos errores

En lenguaje simple

Es aprender a pedir bien, no a programar el modelo desde cero.

Hallucinations

Una **alucinación** ocurre cuando el modelo responde con seguridad, pero inventa o distorsiona información.

Puede pasar al

- citar fuentes que no existen
- afirmar datos incorrectos
- completar vacíos con texto plausible

Regla de negocio

Si el caso es sensible, la salida debe validarse.

Embeddings

Los **embeddings** son representaciones numéricas del significado.

Para qué se usan mucho hoy

- buscar textos parecidos
- comparar significado
- encontrar documentos relevantes
- alimentar sistemas RAG

Idea simple

Permiten que una máquina compare cercanía semántica, no solo palabras exactas.

Base de datos vectorial

Es una base pensada para guardar y buscar embeddings.

Su rol típico

- almacenar fragmentos de documentos
- recuperar lo más relevante para una consulta
- ayudar a responder con contexto específico

Traducción ejecutiva

Es una pieza común en sistemas que “conversan con documentos”.

RAG

RAG significa **Retrieval-Augmented Generation**.

Consiste en recuperar información relevante antes de responder.

Flujo simplificado

1. El usuario pregunta.
2. El sistema busca información relacionada.
3. El modelo responde con ese contexto adicional.

Valor

Reduce la dependencia exclusiva de lo que el modelo aprendió en entrenamiento.

Fine-tuning

Fine-tuning es ajustar un modelo para que funcione mejor en una tarea o estilo específico.

Puede servir para

- respuestas con formato fijo
- lenguaje de una industria
- tono institucional
- tareas repetitivas muy concretas

Ojo

No todo problema se resuelve con fine-tuning; muchas veces basta con mejor contexto y mejores prompts.

Tool use o function calling

Hoy muchos modelos pueden usar **herramientas**.

Eso significa que no solo generan texto: también pueden pedir acciones al sistema.

Ejemplos

- consultar una base de datos
 - buscar en la web
 - leer archivos
 - enviar un correo
 - ejecutar una acción en un sistema
-

Agentes

Un **agente** es un sistema que usa un modelo para perseguir un objetivo con varios pasos.

A diferencia de un chat simple, puede

- planificar
- usar herramientas
- consultar fuentes
- ejecutar acciones
- revisar resultados

Idea clave

No es solo “responder”, sino coordinar trabajo.

AI agents, copilots y automatización

Son conceptos cercanos, pero no idénticos:

- **copilot**: ayuda a una persona
- **agente**: ejecuta pasos con cierta autonomía
- **automatización**: flujo que corre con reglas definidas

Pregunta útil

¿Qué nivel de autonomía queremos realmente?

Reasoning models

Hoy se habla mucho de **reasoning models** o modelos de razonamiento.

La idea general

Son modelos preparados para resolver tareas más complejas:

- planificación
- problemas de varios pasos
- análisis más exigente
- toma de decisiones asistida

Traducción práctica

No todo requiere un modelo “más pensante”; depende del tipo de tarea.

Modelos pequeños y modelos grandes

No siempre gana el modelo más grande.

Hoy conviven

- modelos frontier, más potentes
- modelos pequeños, más rápidos y baratos
- modelos especializados para tareas concretas

Criterios reales

- costo
 - velocidad
 - privacidad
 - calidad requerida
-

Modelos cerrados, abiertos y open-weight

Es una distinción cada vez más importante.

- **cerrados**: el proveedor controla el modelo y su acceso
- **abiertos en pesos / open-weight**: se pueden descargar y desplegar
- **afinados internamente**: adaptados por la organización

Implicancia

La elección del modelo también es una decisión de control, costo y dependencia.

MCP

MCP significa **Model Context Protocol**.

Es un protocolo emergente para conectar modelos con datos, herramientas y servicios de forma estandarizada.

Idea simple

Busca que distintos sistemas de IA puedan conectarse a fuentes externas sin integraciones totalmente artesanales cada vez.

Por qué aparece tanto hoy

Porque el ecosistema se está moviendo desde “chat” hacia “sistemas conectados”.

Evals

Evaluations o **evals** son pruebas para medir si una solución de IA realmente funciona bien.

Sirven para revisar

- precisión
- consistencia
- formato
- seguridad
- cumplimiento de reglas

Idea clave

En IA no basta con que “parezca bueno” en una demo.

Guardrails

Los **guardrails** son controles para limitar comportamientos no deseados.

Ejemplos

- bloquear ciertos tipos de salida
- exigir validación humana
- restringir acceso a datos
- evitar acciones no autorizadas

Traducción

Son cinturones de seguridad para sistemas con IA.

Privacidad, sesgos y seguridad

Tres palabras que deben entrar temprano en cualquier conversación de adopción.

Riesgos frecuentes

- fuga de datos
 - respuestas sesgadas
 - automatización sin control
 - dependencia excesiva del proveedor
 - mal uso de contenido sintético
-

Deepfakes y contenido sintético

La IA actual puede producir contenido muy convincente.

Eso abre oportunidades, pero también riesgos

- fraude
- desinformación
- suplantación
- daño reputacional

Idea clave

Mientras mejor genera la IA, más importante se vuelve verificar origen y contexto.

Casos de uso que hoy son comunes

- resumen de reuniones y documentos
 - asistentes de atención a clientes
 - búsqueda sobre bases de conocimiento
 - generación de propuestas y correos
 - apoyo a análisis en áreas legales, comerciales o de operaciones
 - copilotos de productividad
-

Donde suele estar el valor real

En organizaciones, el impacto suele venir de combinar cuatro cosas:

- modelo
- contexto
- integración
- proceso

Fórmula simple

Valor = IA + datos útiles + buen diseño de trabajo

Cómo leer el panorama actual sin perderse

No es necesario dominar toda la jerga técnica.

Lo importante es poder distinguir:

- qué hace el modelo
 - qué hace el sistema alrededor
 - dónde están los datos
 - quién valida la salida
 - cómo se mide el valor
-

Idea de cierre

La conversación actual sobre IA ya no trata solo de “usar un chatbot”.

Trata de entender cómo combinar:

- modelos
- datos
- herramientas
- personas
- controles

para rediseñar trabajo, productos y decisiones.

Conceptos que conviene recordar

- IA
 - IA generativa
 - LLM
 - multimodalidad
 - prompt
 - contexto
 - embeddings
 - RAG
 - tool use
 - agentes
 - reasoning models
 - evals
 - guardrails
 - MCP
-

Referencias sugeridas

- OpenAI, “Prompting”. <https://platform.openai.com/docs/guides/prompting>
- OpenAI, “Function calling”. <https://platform.openai.com/docs/guides/function-calling>
- OpenAI, “File search”. <https://platform.openai.com/docs/guides/tools-file-search>
- OpenAI Help Center, “Retrieval Augmented Generation (RAG) and Semantic Search for GPTs”. <https://help.openai.com/en/articles/8868588-retrieval-augmented-generation-rag-and-semantic-search-for-gpts>
- OpenAI, “Reasoning models”. <https://platform.openai.com/docs/guides/reasoning>
- OpenAI, “Model optimization”. <https://platform.openai.com/docs/guides/fine-tuning>
- Anthropic, “Model Context Protocol (MCP)”. <https://docs.anthropic.com/en/docs/mcp>
- Anthropic, “Building with extended thinking”. <https://docs.anthropic.com/en/docs/build-with-claude/extended-thinking>
- Google AI for Developers, “Long context”. <https://ai.google.dev/gemini-api/docs/long-context>

- Google AI for Developers, “Function calling with the Gemini API”. <https://ai.google.dev/gemini-api/docs/function-calling>