

Bonus: Cómo usar menos tokens sin perder calidad

Eficiencia, costo y diseño de prompts

2026-04-30

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Bonus

Cómo usar menos tokens sin perder calidad

Eficiencia, costo y diseño de prompts

Por qué importa esta clase

Los modelos de lenguaje cobran por token.

Pero el costo no es solo monetario:

- más tokens en el contexto = mayor latencia
- contextos muy grandes degradan la atención del modelo
- la ventana de contexto tiene un límite físico
- los sistemas mal diseñados escalan muy mal en costo

Idea central

Diseñar con eficiencia de tokens no es optimización prematura: es parte del diseño de cualquier sistema de IA en producción.

¿Qué es un token?

Un token es la unidad mínima que el modelo procesa.

No equivale exactamente a una palabra ni a un carácter.

Reglas aproximadas para estimar

- 1 token ~ 4 caracteres en inglés
- 1 token ~ 3 caracteres en español
- una palabra en inglés ~ 1–1.3 tokens
- una palabra en español ~ 1.3–2 tokens

Por qué importa esto

El mismo contenido semántico cuesta sistemáticamente más tokens en español que en inglés.

El idioma importa más de lo que parece

Tomemos una instrucción simple:

Versión	Texto	Tokens aprox.
Español	“Resume el siguiente documento en tres puntos clave.”	~12
Inglés	“Summarize the following document in three key points.”	~10

La diferencia parece pequeña en un solo prompt.

En un sistema con miles de llamadas diarias, se acumula.

¿Cuánto más cuesta el español?

Para el mismo contenido semántico, el español genera entre un **20 % y un 40 % más de tokens** que el inglés.

Las razones técnicas

- el tokenizador de la mayoría de los modelos fue entrenado principalmente con texto en inglés
- palabras largas en español se fragmentan en más subpalabras
- tildes y caracteres especiales también suman

Consecuencia práctica

Un sistema prompt en español de 500 tokens equivale a uno en inglés de 300–380 tokens con el mismo significado.

Trabajar en inglés: la recomendación más impactante

Si el flujo lo permite, **escribir los prompts, instrucciones y system messages en inglés** es la intervención de mayor impacto.

Cuándo aplica bien

- sistema prompts y reglas internas
- instrucciones del agente
- definición de skills y planes
- CLAUDE.md y archivos de configuración

Cuándo no aplica

- cuando la respuesta final debe estar en español
 - cuando el usuario interactúa directamente en español
 - cuando el dominio contiene terminología legal o regulatoria en español
-

Ejemplo: mismo system prompt, dos idiomas

En español (~68 tokens)

Eres un asistente de análisis financiero.
Solo respondes preguntas sobre indicadores económicos de Chile.
Usas datos verificables. No das recomendaciones de inversión.
Si no tienes información, lo dices explícitamente.

En inglés (~52 tokens)

You are a financial analysis assistant.
Only answer questions about Chilean economic indicators.
Use verifiable data. Do not give investment advice.
If you lack information, say so explicitly.

Ahorro: ~24 % en este caso

En un sistema con el system prompt enviado en cada llamada, ese ahorro se multiplica por el número de requests.

La instrucción de idioma: el puente

Trabajar con prompts en inglés no significa que el usuario deba escribir o leer en inglés.

Se puede combinar así:

```
You are an assistant for AFP Model's customer service team.  
Always respond in Spanish, using formal tone.  
Only use information from the provided documents.
```

El prompt está en inglés. La respuesta sale en español.

Técnicas de ahorro de tokens

1. Eliminar cortesías y relleno

Los modelos no necesitan frases de introducción.

Antes

Por favor, cuando tengas un momento, me ayudarías a revisar el siguiente texto y hacer un resumen conciso de los puntos más importantes que se mencionan en él. Muchas gracias.

[texto]

Después

Summarize the key points of the following text.

[texto]

Ahorro estimado: 30–50 tokens en este ejemplo

La calidad de la respuesta no cambia.

2. Usar formato estructurado en vez de prosa

Las instrucciones en lista son más compactas que las mismas instrucciones en prosa.

En prosa (~40 tokens)

Necesito que analices el texto y primero identifiques el tema principal, luego detectes el tono, y finalmente propongas tres palabras clave.

En lista (~28 tokens)

Analyze the text:

1. Main topic
 2. Tone
 3. Three keywords
-

3. Limitar el largo del output

Si no necesitas una respuesta larga, pedirle explícitamente al modelo que sea breve ahorra tokens de salida.

Los tokens de salida también tienen costo (y en muchos modelos, mayor costo que los de entrada).

Instrucciones útiles

Answer in maximum 2 sentences.
Return only the JSON, no explanation.
One bullet per item, no elaboration.

4. No repetir contexto que ya está en el sistema

Un error frecuente: repetir en cada mensaje de usuario información que ya está en el system prompt.

Ineficiente

[system]: You are an assistant for AFP Model...
[user]: Como asistente de AFP Model que solo usa documentos oficiales, necesito que respondas esta pregunta...

Eficiente

[system]: You are an assistant for AFP Model...
[user]: ¿Cuáles son los requisitos para pensionarse por vejez?

5. Resumir el historial de conversación

En sesiones largas, el historial acumulado puede consumir la mayoría de la ventana de contexto.

Estrategia

En lugar de enviar toda la conversación, comprimir el historial:

[system]: ...instrucciones...
[summary]: Previous conversation summary: the user asked about retirement requirements. We confirmed age 65 applies for men under the general regime.
[user]: ¿Y cuál es el mínimo de años cotizados?

Resultado

Se mantiene la coherencia de la conversación usando una fracción de los tokens.

6. Truncar o resumir documentos antes de enviarlos

Si el documento completo no cabe o no es necesario, conviene:

- extraer solo las secciones relevantes
- pedir primero un resumen y luego trabajar sobre él
- usar RAG para traer solo los fragmentos pertinentes

Regla práctica

No envíes 40 páginas cuando la respuesta está en 2 párrafos. RAG existe precisamente para este problema.

7. Prompt caching

Anthropic y otros proveedores ofrecen **prompt caching**: el sistema almacena en caché la parte estática del prompt (system message, documentos de referencia) y no la re-procesa en cada llamada.

Cómo funciona

```
[CACHED] system message + documentos base
      ↓
[NEW]    pregunta del usuario
```

Solo se cobra el procesamiento de la parte nueva.

Ahorro potencial

En sistemas donde el system prompt es largo y se envía miles de veces al día, el ahorro puede ser del 80–90 % en tokens de entrada.

Prompt caching: cuándo aplica

Condición	¿Conviene cachear?
System prompt largo y estático	Sí — primer candidato
Documentos de referencia fijos	Sí — alto impacto
Few-shot examples repetidos	Sí
Historial de conversación variable	No — cambia en cada turno
Pregunta del usuario	No — siempre es nueva

Requisito técnico

La parte cacheada debe aparecer al inicio del contexto y superar un mínimo de tokens (varía por proveedor).

Tarea	Modelo sugerido
-------	-----------------

8. Elegir el modelo correcto para la tarea

Los modelos más grandes cuestan más por token.

No todas las tareas requieren el modelo más potente.

Tarea	Modelo sugerido
Clasificación simple, sentimiento	Haiku / Flash
Resumen estándar, extracción	Sonnet
Razonamiento complejo, planificación	Opus
Agentes multi-paso con herramientas	Sonnet o Opus según complejidad

Regla práctica

Usar el modelo más pequeño que resuelve la tarea correctamente.

Resumen de técnicas

Técnica	Impacto	Dificultad
Prompts en inglés	Alto	Bajo
Eliminar relleno y cortesías	Medio	Bajo
Instrucciones en lista, no prosa	Medio	Bajo
Limitar largo del output	Alto	Bajo
No repetir el system en el user turn	Medio	Bajo
Resumir historial de conversación	Alto	Medio
Truncar documentos / usar RAG	Alto	Medio
Prompt caching	Muy alto	Medio-alto
Modelo correcto para la tarea	Alto	Bajo

Un ejemplo integrado

Sistema de análisis de noticias que corre 500 veces por día.

Sin optimización

- System prompt en español: $800 \text{ tokens} \times 500 = 400,000 \text{ tokens/día}$
- Sin caching, sin truncación, sin límite de output

Con optimización

- System prompt en inglés: ~580 tokens (−27 %)
- Caching activado: solo se cobra en el primer request del lote
- Output limitado a campos JSON: −40 % en tokens de salida
- Modelo Haiku para clasificación simple

Resultado

El mismo sistema, a una fracción del costo diario.

Lo que no se debe recortar

Ahorrar tokens no significa degradar la calidad del contexto.

No conviene recortar

- las restricciones de seguridad y guardrails
- la definición del rol del agente
- las instrucciones sobre qué no debe hacer el sistema
- el criterio de éxito de la tarea

Regla final

Elimina verbosidad, no claridad. Comprime relleno, no restricciones.

Checklist de eficiencia

Antes de desplegar un sistema en producción, revisar:

- ☐ ¿El system prompt está en inglés?
 - ☐ ¿Tiene frases de cortesía o relleno eliminables?
 - ☐ ¿Está activo el prompt caching en las partes estáticas?
 - ☐ ¿El output tiene longitud máxima definida?
 - ☐ ¿Se está usando el modelo mínimo suficiente para la tarea?
 - ☐ ¿Los documentos se entregan por RAG en lugar de completos?
 - ☐ ¿El historial largo se comprime o resume?
-

Idea de cierre

Diseñar con eficiencia de tokens no es solo una decisión técnica.

Es una decisión de producto:

- los sistemas más eficientes son más rápidos
- los sistemas más eficientes son más baratos de escalar
- los sistemas más eficientes tienen menos ruido en el contexto
- los sistemas más eficientes son más fáciles de mantener y auditar

El contexto bien diseñado no solo es útil: es compacto.

Referencias sugeridas

- Anthropic, “Prompt caching”. <https://docs.anthropic.com/en/docs/build-with-claude/prompt-caching>
- OpenAI, “Managing tokens”. <https://platform.openai.com/docs/guides/production-best-practices>
- OpenAI Tokenizer (herramienta interactiva). <https://platform.openai.com/tokenizer>
- Anthropic, “Models overview” (tabla de costos por modelo). <https://docs.anthropic.com/en/docs/about-claude/models>