

Módulo 3: Actividad

Attention Is All You Need — NotebookLM

2026-04-30

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Módulo 03

Actividad: Attention Is All You Need

Prompts y guion para generar el material con NotebookLM

Qué contiene este documento

Tres insumos listos para usar en NotebookLM:

- **Prompt 1:** para generar el video / audio podcast
- **Prompt 2:** para generar las diapositivas
- **Documento libre:** guion completo para cargar como fuente adicional

Paper fuente: Vaswani et al. (2017). *Attention Is All You Need*. NeurIPS.

Cómo usar este material

1. Sube el PDF del paper a NotebookLM como fuente
2. Para el video: usa el **Prompt 1** como instrucción al generar el audio
3. Para las diapositivas: usa el **Prompt 2** como instrucción
4. Para el documento libre: cópialo como nota o súbelo como archivo de texto adicional

El documento libre le da a NotebookLM el contenido ya redactado para que no se aleje del enfoque del curso.

Prompts para NotebookLM

Prompt 1 — Video / audio podcast

Contexto del curso:

Soy docente de un programa de especialización en IA Generativa y LLMs para la Transformación Organizacional, dirigido a profesionales y directivos con formación en gestión, sin background técnico en deep learning. Ya vimos qué es un LLM, atención de forma intuitiva, embeddings y RAG.

Objetivo: video de 5 a 7 minutos para introducir el paper en clase, antes de una discusión grupal. Debe terminar con una pregunta abierta.

Audiencia: profesionales y directivos. Sin fórmulas. Sí entienden conceptos de negocio, productividad y tecnología aplicada.

Estructura:

1. Qué problema tenían los modelos anteriores (RNN, LSTM):
secuencialidad, pérdida de dependencias largas, no escala.
2. Qué propone el paper: atención pura, sin recurrencia.
3. Por qué fue importante: paralelización, escala, dependencias largas.
De ahí vienen GPT, Claude, Gemini.
4. Cierre: ¿qué cambia cuando el modelo considera todo el contexto al mismo tiempo en lugar de procesarlo paso a paso?

Tono: conversacional, accesible, como docente antes de una actividad.
Sin fórmulas. Con analogías simples si ayudan.

Prompt 2 — Diapositivas

Contexto del curso:

Soy docente de un programa de especialización en IA Generativa y LLMs para la Transformación Organizacional. Audiencia: profesionales con formación en gestión. Ya vimos LLMs, embeddings, atención y RAG.

Objetivo: 6 diapositivas en español para introducir el paper "Attention Is All You Need" (Vaswani et al., 2017) antes de una actividad grupal.

Estructura:

Slide 1 - Los modelos antes del Transformer

Qué limitaba a RNN y LSTM: secuencialidad, dependencias largas, dificultad para escalar.

Slide 2 - Atención es todo lo que necesitas

Reemplazar recurrencia por atención pura. Cada token se relaciona directamente con cualquier otro.

Slide 3 - Query, Key y Value

Sin fórmulas: el modelo pregunta, compara y decide qué información usar de cada parte del contexto.

Slide 4 - Paralelización y escala

Entrenamiento paralelo. Modelos más grandes con más datos.

Slide 5 - De este paper vienen los LLMs actuales

GPT, BERT, Claude, Gemini y casi todos los modelos modernos son Transformers.

Slide 6 - Para discutir

¿Qué cambia cuando el modelo puede mirar todo el contexto a la vez?
¿Qué implica eso para prompts, RAG y límites del modelo?

Formato: título + 3 a 4 bullets cortos. Sin jerga innecesaria.

Documento libre

Para cargar como fuente adicional en NotebookLM

Este documento está redactado para subirse como nota o archivo de texto junto al PDF del paper.

NotebookLM lo usará como referencia de contenido, nivel y enfoque para generar el material sin alejarse del curso.

Encabezado del documento libre

Curso: Especialización en IA Generativa y LLMs para la Transformación Organizacional, FEN U. de Chile.

Audiencia: profesionales y directivos con formación en gestión.
Sin background técnico en deep learning.

Propósito: introducir el paper "Attention Is All You Need" antes de una actividad grupal. Tono divulgativo. Sin fórmulas.

Paper de referencia: Vaswani et al. (2017). Attention Is All You Need. NeurIPS. <https://arxiv.org/abs/1706.03762>

Slide 1 del guion

Título: Attention Is All You Need

Vaswani et al., 2017 — el paper que cambió la historia de los modelos de lenguaje.

Esta presentación introduce el argumento central del paper para entender por qué fue tan influyente y qué conexión tiene con los LLMs que usamos hoy.

Slide 2 del guion

El problema que existía antes

Los modelos dominantes antes del Transformer eran las redes recurrentes: RNN y LSTM. Procesaban el texto de forma secuencial, token por token, acumulando información en un estado interno.

Eso generaba dos problemas: las relaciones entre palabras distantes se perdían porque la información tenía que “sobrevivir” muchos pasos intermedios. Y el entrenamiento no podía ejecutarse en paralelo, lo que hacía muy costoso escalar estos modelos.

Slide 3 del guion

La propuesta del paper

El paper propone eliminar la recurrencia por completo y reemplazarla por un mecanismo de atención puro.

En lugar de procesar el texto paso a paso, el Transformer permite que cada parte del texto se relacione directamente con cualquier otra, en una sola operación.

De ahí viene el título: la atención es todo lo que necesitas. No hace falta recurrencia ni convoluciones.

Slide 4 del guion

Cómo funciona la atención (sin fórmulas)

Cuando el modelo procesa un token, genera tres cosas:

- una **query**: qué información está buscando
- una **key**: qué tipo de información contiene ese token
- un **value**: el contenido que puede aportar

El mecanismo compara la query de cada token con las keys de todos los demás y decide cuánto peso darle a cada uno. Eso determina qué información se incorpora en la respuesta final.

Slide 5 del guion

Por qué eso fue tan importante

Al eliminar la secuencialidad, el Transformer habilitó dos cosas:

Primero, el entrenamiento puede ejecutarse en paralelo. Ya no hay que esperar el paso N para empezar el N+1. Eso permite entrenar modelos mucho más grandes con mucho más dato.

Segundo, las relaciones entre partes distantes del texto se capturan directamente, sin depender de que la información sobreviva una cadena larga de pasos intermedios.

Slide 6 del guion

El impacto real

GPT, BERT, Claude, Gemini, Llama y prácticamente todos los modelos de lenguaje relevantes hoy son Transformers.

El mecanismo propuesto en 2017 es la arquitectura sobre la que se construyen los sistemas de IA generativa que vemos en este curso.

Entender atención no es un ejercicio teórico: es entender por qué estos modelos funcionan como funcionan y cuáles son sus límites reales.

Slide 7 del guion

Pregunta para el grupo

¿Qué cambia, en términos prácticos, cuando un modelo puede considerar todo el contexto al mismo tiempo en lugar de procesarlo paso a paso?

¿Cómo afecta eso a cómo construimos prompts, cómo armamos el contexto en RAG y cómo pensamos los límites del modelo?

Referencia

Paper fundacional

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*. Advances in Neural Information Processing Systems (NeurIPS).

<https://arxiv.org/abs/1706.03762>