

Módulo 3: Arquitectura y Funcionamiento de los LLMs

Fundamentos técnicos y panorama actual de modelos

2026-04-20

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Módulo 03

Clase 01: Arquitectura y funcionamiento de los LLMs

De los conceptos base al panorama actual de modelos

Objetivo de la sesión

- Entender cómo procesan lenguaje los LLMs
 - Revisar tokens, embeddings, atención, contexto y parámetros
 - Distinguir modelos abiertos, cerrados y open-weight
 - Comparar familias como GPT, Claude, Gemini y Llama
 - Traducir estos conceptos a implicancias prácticas para organizaciones
-

Pregunta de apertura

Cuando una organización dice “queremos usar IA generativa”, ¿de qué pieza está hablando realmente?

- de un chatbot
 - de un modelo
 - de una aplicación
 - de una integración
 - de un sistema completo
-

El stack

Un LLM no es toda la solución

En la práctica, una solución generativa suele combinar:

- interfaz o canal
- modelo de lenguaje
- contexto de documentos o datos
- herramientas o APIs
- reglas de negocio
- monitoreo y seguridad

Idea clave

El LLM es una capa central, pero no equivale al sistema completo.

¿Qué es un LLM?

Un **Large Language Model** es un modelo entrenado con grandes volúmenes de texto para estimar la continuación más probable dado un contexto.

Tareas típicas

- responder preguntas
 - resumir
 - redactar
 - traducir
 - clasificar
 - extraer información
-

Tokens

Los modelos no leen texto como nosotros lo vemos.

Trabajan con **tokens**, unidades pequeñas que pueden ser:

- fragmentos de palabra
- palabras completas
- signos
- números frecuentes

Implicancia práctica

Todo input, output, costo y límite de contexto se mide en tokens.

Ejemplo intuitivo de tokenización

La frase:

“La inteligencia artificial transforma procesos.”

podría dividirse en piezas como:

- La
- intelig
- encia
- artificial
- transforma
- procesos
- .

Idea clave

El modelo procesa unidades operativas, no palabras completas “como humano”.

Embeddings

Cada token se transforma en una representación numérica.

Eso permite que el modelo capture relaciones como:

- significado
- similitud
- contexto de uso
- cercanía semántica

Idea simple

Los embeddings son el idioma interno del modelo.

Atención

La **atención** es el mecanismo que permite al modelo ponderar qué partes del contexto son más relevantes en cada momento.

Intuición

Cuando genera una palabra, no mira todo el texto con el mismo peso.
Algunas partes del contexto importan más que otras.

Ventana de contexto

La **context window** es la cantidad máxima de tokens que el modelo puede considerar al mismo tiempo.

Importa porque afecta

- largo de instrucciones
 - cantidad de documentos que caben
 - calidad de tareas extensas
 - costo total de la consulta
-

Parámetros del modelo

Los **parámetros** son los pesos internos que el modelo ajusta durante entrenamiento.

Idea importante

Más parámetros no garantizan mejor desempeño en todos los casos.

Parámetros de generación

También controlamos cómo responde el modelo con variables como:

- temperatura
- top-p
- top-k
- max tokens

Regla operativa

Análisis y extracción: baja temperatura.

Ideación y creatividad: temperatura mayor.

Qué hacen bien los LLMs

- sintetizar información extensa
 - reformular contenido
 - traducir y adaptar tono
 - clasificar texto
 - extraer patrones desde lenguaje
 - ayudar a explorar ideas
-

Qué hacen mal o con riesgo

- inventar hechos
 - citar fuentes inexistentes
 - equivocarse con exceso de confianza
 - degradarse en tareas largas sin control
 - fallar si no tienen contexto suficiente
-

Modelos

Modelos cerrados, abiertos y open-weight

Tipo	Ventaja típica	Desafío típico
Cerrado	facilidad de uso	menor control
Open-weight	flexibilidad	mayor complejidad operativa
Afinado propio	ajuste al dominio	mayor costo de desarrollo

Panorama actual de familias de modelos

Modelos cerrados relevantes

- GPT de OpenAI
- Claude de Anthropic
- Gemini de Google

Modelos abiertos u open-weight relevantes

- Llama de Meta
 - Mistral
 - Qwen
 - gpt-oss de OpenAI
-

Lectura práctica del mercado

- OpenAI combina familia GPT cerrada con modelos open-weight
 - Anthropic enfatiza razonamiento, seguridad y uso empresarial
 - Google enfatiza multimodalidad y contexto largo
 - Meta empuja apertura, control y despliegue flexible con Llama
-

¿Cuál modelo elegir?

La elección depende de:

- caso de uso
 - presupuesto
 - velocidad requerida
 - privacidad
 - nivel de control
 - trazabilidad
 - integración con sistemas existentes
-

Idea de cierre

Comprender arquitectura de LLMs no busca convertir a todos en ingenieros del modelo.

Busca permitir mejores decisiones sobre:

- qué usar
 - cómo integrarlo
 - qué controlar
 - dónde están sus límites
-

Referencias sugeridas

- OpenAI, “Models”. <https://platform.openai.com/docs/models>
- OpenAI, “Compare models”. <https://platform.openai.com/docs/models/compare>
- OpenAI, “gpt-oss”. <https://platform.openai.com/docs/models/gpt-oss>
- Anthropic, “Models overview”. <https://docs.anthropic.com/en/docs/about-claude/models>
- Google AI for Developers, “Gemini models”. <https://ai.google.dev/models/gemini>
- Meta, “Open Source AI”. <https://ai.meta.com/opensourceAI/>
- Vaswani et al. (2017), *Attention Is All You Need*. <https://arxiv.org/abs/1706.03762>