

Módulo 3: Atención en LLMs

Cómo el modelo prioriza contexto

2026-04-27

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Módulo 03

Atención en LLMs

Cómo el modelo prioriza contexto

Objetivo de la sesión

- Entender qué problema resuelve la atención
 - Construir una intuición operativa del mecanismo
 - Conectar atención con calidad de prompt y uso de contexto
 - Preparar la lectura del paper *Attention Is All You Need*
-

¿Qué es la atención?

La atención es el mecanismo que permite al modelo ponderar qué partes del contexto son más relevantes en cada momento.

Intuición

Cuando genera una palabra, no mira todo con el mismo peso.

¿Qué problema resuelve?

En lenguaje natural, el significado depende del contexto.

No es lo mismo:

- **banco** como institución financiera
- **banco** como asiento

Idea clave

La atención ayuda a decidir qué partes del contexto aclaran el sentido correcto.

Intuición operativa

Cuando el modelo genera una palabra nueva:

- mira los tokens previos
- estima cuáles son más relevantes
- les da más peso a algunos
- y menos peso a otros

Lectura simple

No recuerda todo igual: prioriza dinámicamente.

Ejemplo intuitivo

Tomemos esta frase:

“El analista revisó el informe porque necesitaba verificar si los beneficios estaban correctamente calculados.”

Si el modelo quiere continuar después de **beneficios**, probablemente pondrá más atención en:

- **informe**
- **verificar**
- **calculados**

y menos en:

- el
 - porque
 - los
-

Atención como mecanismo de foco

Podemos pensarlo como un sistema de foco variable.

No todas las palabras pesan igual

- algunas definen el tema
- otras aclaran relaciones
- otras casi no aportan significado por sí solas

Idea clave

La atención permite construir relevancia contextual token por token.

Queries, keys y values sin fórmulas

Una forma simple de explicarlo es esta:

- cada token genera una **query**: qué está buscando ahora
- cada token ofrece una **key**: qué tipo de información contiene
- cada token aporta una **value**: el contenido que puede entregar

Intuición

El modelo compara la query actual con las keys del contexto y decide de cuáles values conviene tomar más información.

Ejemplo simple de queries, keys y values

Si la pregunta es:

“¿Qué documentos necesito para pensionarme?”

La query implícita buscará información relacionada con:

- documentos
- requisitos
- pensionarme

Entonces fragmentos sobre:

- certificados
- edad legal
- formularios
- solicitud de pensión

recibirán más peso que otros sobre canales generales o información secundaria.

¿Por qué fue tan importante?

La atención permitió:

- capturar relaciones entre palabras distantes
- procesar contexto de forma más flexible
- escalar mejor a textos complejos

Idea clave

Gran parte del salto de los LLMs modernos pasa por este mecanismo.

Atención y calidad del prompt

La forma en que escribimos un prompt afecta qué partes del contexto destacan más.

Por eso ayuda:

- separar instrucciones de contexto
- usar formato claro
- destacar restricciones
- ordenar bien la información

Lectura práctica

Un buen prompt también guía la atención del modelo.

Riesgo práctico

La atención no garantiza:

- verdad factual
- razonamiento correcto
- priorización siempre adecuada

Regla simple

Si el contexto está mal armado, el modelo puede enfocarse en lo menos importante.

Ejemplo aplicado a una tarea organizacional

Supongamos este prompt:

“Responde al afiliado usando solo la normativa vigente. Si no hay base suficiente, indícalo explícitamente. Consulta: ¿puedo pensionarme anticipadamente?”

Si el contexto está bien estructurado, la atención debería priorizar:

- solo la normativa vigente
- si no hay base suficiente
- pensionarme anticipadamente

Si el contexto estuviera desordenado, el modelo podría apoyarse en fragmentos menos relevantes.

Resumen operativo sobre atención

- ayuda a ponderar qué partes del contexto importan más
- permite conectar palabras o fragmentos distantes
- mejora la relevancia local de cada paso de generación
- depende mucho de cómo está armado el contexto

Pregunta para discutir

¿Qué pasa si una instrucción crítica queda escondida entre demasiado texto irrelevante?

Cierre

Entender atención ayuda a leer mejor tres cosas:

- la arquitectura Transformer
 - la calidad real del contexto que entregamos
 - el sentido del paper fundacional que aparece en la actividad de la clase 01
-

Actividad grupal breve: paper fundacional

Texto base: *Attention Is All You Need* (Vaswani et al., 2017)

Objetivo

Entender por qué este paper fue tan influyente y conectar su propuesta con lo que hoy vemos en LLMs.

Formato

- grupos de 3 a 4 personas
 - duración máxima: 30 minutos
 - insumo mínimo: abstract + introducción del paper
-

Instrucciones de trabajo

Cada grupo debe leer el abstract y la introducción y responder estas preguntas:

1. ¿Qué limitación de los modelos anteriores identifica el paper?
2. ¿Cuál es la propuesta central del Transformer?
3. ¿Por qué la atención aparece como una innovación tan importante?
4. ¿Qué conexión ven entre este paper y los LLMs actuales?

Regla

No se trata de resumir todo el paper, sino de identificar su argumento central.

Producto esperado del grupo

Cada grupo prepara una mini-síntesis de 3 partes:

- **Problema anterior:** qué estaba fallando o limitando a los modelos previos
- **Aporte del paper:** qué cambia con el Transformer
- **Impacto actual:** por qué esto sigue importando en la arquitectura de los LLMs

Formato sugerido

3 a 5 bullets o una intervención oral de 1 minuto.

Guía para orientar la discusión

Si el grupo se traba, puede apoyarse en esta pista:

- antes había más secuencialidad y menos paralelización
- el paper propone apoyarse solo en atención
- eso mejora la capacidad de modelar dependencias y escalar entrenamiento

Conexión con esta clase

La pregunta de fondo es:

¿Por qué entender atención ayuda a entender por qué los LLMs modernos son posibles?

Cierre y puesta en común

En plenario, cada grupo comparte:

- una idea del paper que le pareció fundacional
- una conexión con conceptos vistos hoy: atención, contexto, escalabilidad o arquitectura

Criterio de éxito

Si al terminar pueden explicar por qué este paper marca un punto de inflexión, la actividad cumplió su objetivo.
