

Técnicas de Tokenización

Cómo convierten texto en unidades procesables los modelos de lenguaje

2026-04-27

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Objetivo

Entender las principales técnicas de tokenización

- qué problema resuelven
 - cómo segmentan el texto
 - cuáles son sus ventajas y límites
 - por qué la tokenización subword domina en LLMs modernos
-

¿Qué es tokenizar?

Tokenizar es convertir texto en unidades más pequeñas que un sistema puede procesar.

Esas unidades pueden ser:

- caracteres
- palabras completas
- fragmentos de palabra
- signos o símbolos

Idea clave

El modelo no opera directamente sobre texto “humano”, sino sobre tokens.

¿Por qué importa?

La técnica de tokenización afecta:

- tamaño del vocabulario
 - costo computacional
 - longitud efectiva del contexto
 - capacidad para manejar palabras nuevas
 - desempeño en distintos idiomas
-

Problema de fondo

El lenguaje no viene segmentado de forma perfecta

Ejemplos:

- palabras muy largas
- nombres propios nuevos
- errores ortográficos
- abreviaturas
- emojis
- mezcla de idiomas

Pregunta central

¿Cómo dividimos el texto sin perder demasiada información y sin volver el sistema inmanejable?

Técnica 1

Tokenización por caracteres

Cada carácter es un token.

Ejemplo

gato → g, a, t, o

Ventajas

- vocabulario muy pequeño
- nunca hay palabras fuera de vocabulario
- maneja bien errores ortográficos o palabras nuevas

Límites

- secuencias mucho más largas
 - menor eficiencia
 - más difícil capturar significado semántico de alto nivel
-

Técnica 2

Tokenización por palabras

Cada palabra completa se trata como un token.

Ejemplo

el gato duerme en el sillón

→ el, gato, duerme, en, el, sillón

Ventajas

- interpretación intuitiva
- secuencias más cortas que con caracteres
- buena legibilidad para análisis simple

Límites

- vocabulario enorme
 - problema de palabras fuera de vocabulario
 - mala adaptación a errores, variantes y morfología rica
-

Técnica 3

Tokenización por reglas

Se usan reglas lingüísticas o expresiones regulares para segmentar:

- espacios
- signos de puntuación
- prefijos o sufijos
- patrones conocidos

Ejemplo

Hola, mundo!

→ Hola, ,, mundo, !

Ventajas

- simple de implementar
- controlable
- útil en pipelines clásicos de NLP

Límites

- frágil ante excepciones
 - difícil de escalar a múltiples idiomas
 - depende mucho del diseño manual
-

Técnica 4

Tokenización subword

Divide las palabras en fragmentos frecuentes.

Ejemplo

internacionalización

podría dividirse como:

- interna
- cional
- ización

Idea clave

Busca un equilibrio entre caracteres y palabras completas.

¿Por qué es importante?

La tokenización subword:

- reduce el tamaño del vocabulario
- maneja palabras raras o nuevas
- conserva patrones frecuentes del lenguaje
- mejora eficiencia frente a tokenización por caracteres

Por eso es el enfoque dominante en LLMs actuales

Principales métodos subword

Byte Pair Encoding (BPE)

Empieza con unidades pequeñas y va fusionando pares frecuentes.

Intuición

Si una combinación aparece muchas veces, conviene tratarla como una unidad estable.

Ejemplo simplificado de BPE

Supongamos que vemos repetidamente:

- `l + a`
- `la + s`

El algoritmo podría aprender:

- `la`
- `las`

Resultado

Fragmentos frecuentes pasan a ser tokens completos.

Ventajas de BPE

- eficiente
- ampliamente usado
- buen equilibrio entre vocabulario y cobertura

Límites

- no siempre respeta fronteras lingüísticas intuitivas
 - puede generar segmentaciones poco naturales
-

WordPiece

Similar a BPE, pero selecciona combinaciones según cuánto mejoran la probabilidad del modelo.

Se hizo muy conocido por su uso en BERT

Ejemplo:

playing → play + ##ing

Ventajas de WordPiece

- buen rendimiento en tareas de lenguaje
- produce piezas reutilizables
- útil para lenguas con variaciones morfológicas

Límites

- requiere entrenamiento cuidadoso del vocabulario
 - la segmentación puede no ser transparente para usuarios
-

Unigram Language Model

Parte de un vocabulario amplio y elimina piezas menos útiles según una función probabilística.

Idea

No construye el vocabulario solo agregando piezas: también descarta las que aportan poco.

Es común en herramientas como SentencePiece

Ventajas de Unigram

- enfoque probabilístico flexible
- buenas segmentaciones en muchos idiomas
- útil cuando no queremos depender de espacios

Límites

- más abstracto de explicar
 - requiere entrenamiento y evaluación adecuados
-

Técnica 5

Byte-level tokenization

En lugar de partir desde caracteres visibles, parte desde bytes.

Ventaja fuerte

Puede representar cualquier texto sin depender directamente de un alfabeto específico.

Uso típico

Modelos como GPT han utilizado variantes de tokenización a nivel de bytes con fusiones subword.

Ventajas

- cobertura total
- robustez ante símbolos extraños
- evita el problema clásico de palabras fuera de vocabulario

Límites

- puede producir secuencias menos intuitivas
- la interpretación humana de los tokens se vuelve más difícil

Comparación rápida

Técnica	Vocabulario	Longitud de secuencia	Manejo de palabras nuevas	Intuición humana
Caracteres	Muy bajo	Muy alta	Muy bueno	Alta
Palabras	Muy alto	Baja	Malo	Muy alta
Reglas	Variable	Media	Regular	Alta
Subword	Medio	Media	Bueno	Media
Byte-level	Bajo a medio	Media/alta	Muy bueno	Baja

Ejemplo comparado

Frase

reorganización digital

Por caracteres

```
r e o r g a n i z a c i ó n d i g i t a l
```

Por palabras

reorganización, digital

Por subword

re, organización, digital

o

reorgan, ización, digital

¿Qué buscamos realmente?

Una buena tokenización intenta lograr equilibrio entre:

- cobertura
 - eficiencia
 - compresión del texto
 - generalización a palabras nuevas
 - utilidad para el modelo
-

Tokenización y contexto

La tokenización afecta directamente cuántos tokens “caben” en una ventana de contexto.

Ejemplo

Dos textos con el mismo número de caracteres pueden producir distinta cantidad de tokens según:

- el idioma
- la rareza del vocabulario
- el tipo de segmentación usado

Implicancia práctica

Costo y capacidad de contexto dependen también de cómo tokeniza el modelo.

Tokenización en distintos idiomas

No todos los idiomas se comportan igual.

Desafíos frecuentes

- idiomas sin separación clara por espacios
- lenguas con mucha flexión morfológica
- palabras compuestas largas
- mezcla de escritura latina y no latina

Conclusión

La técnica óptima puede variar según idioma, dominio y aplicación.

¿Qué usan los LLMs modernos?

En general, variantes de:

- BPE
- WordPiece
- Unigram
- byte-level subword tokenization

Razón principal

Ofrecen el mejor compromiso práctico entre eficiencia, cobertura y capacidad de generalización.

Idea de cierre

Tokenizar no es un detalle técnico menor.

Es una decisión fundamental que afecta:

- cómo entra el lenguaje al modelo
 - cuánto cuesta procesarlo
 - qué tan bien maneja palabras nuevas
 - qué tan eficiente será el sistema completo
-

Actividad breve

Comparar tokenizaciones

Tomen una frase y propongan cómo se segmentaría:

- por caracteres
- por palabras
- por subword

Luego discutan

- cuál sería más eficiente
 - cuál manejaría mejor palabras nuevas
 - cuál usarían en un LLM y por qué
-

Referencias sugeridas

- Sennrich, Haddow y Birch (2016). *Neural Machine Translation of Rare Words with Subword Units*.
- Devlin et al. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*.
- Kudo y Richardson (2018). *SentencePiece: A simple and language independent subword tokenizer and detokenizer for Neural Text Processing*.